


Aula 04 - 10/08/26
Avaliação de Estratégias de Chunking com LangChain
Patrícia Zan de Oliveira

Documentação apresentando etapas, execução e resultado dos desafios propostos.



1. Base de documentos

Utilizar todos os documentos PDF disponíveis na pasta do Google Drive:

- attention_is_all_you_need.pdf
- bert_pretraining.pdf
- bioetica_e_ia.pdf
- escrita_academica_ia.pdf
- gpt3_language_models.pdf
- gpt4_technical_report.pdf
- instruct_gpt.pdf
- llama_foundation_models.pdf
- lora_low_rank_adaptation.pdf
- retrieval_augmented_generation.pdf
- scaling_laws_llm.pdf
- twitter_algoritmo.pdf

2. Extração dos PDFs para Markdown

O código da extração está contido no arquivo “01_ExtracaoDadosPDFToMD.ipynb”, recomenda-se usar o colab.

Ao realizar a extração dos dados do PDF foi observado perda de imagens contidas nos arquivos `<!-- image -->`, formatações também sofreram anomalias como partes com espaços em branco, caracteres e ícones carregados com código html como `&`.

3. Estratégias de Chunking

Foi utilizado o splitter do long chain como proposto, e o código está contido no arquivo "01_Chunking.ipynb". Foram realizados 10 testes para visualizar a diferença de quantidade e tamanhos.

Foi realizado:

1. Leitura dos arquivos .md
2. Execução de 10 testes, resultado da geração de tabela de exemplo:

	Arquivo	Teste	Estratégia	Configuração	Qtd. chunks	Tamanho médio	Tamanho mínimo	Tamanho máximo	Chunks sobrepostos	Overlap (%)	Tokens estimados	Chunks
0	attention_is_all_you_need.md	1	Fixo	200 caracteres, overlap 0	245	192.89	117	200	0.0	0.0	11814.0	[Provided proper attribution is provided, Goog...
1	attention_is_all_you_need.md	2	Fixo	500 caracteres, overlap 0	98	492.66	425	500	0.0	0.0	12070.0	[Provided proper attribution is provided, Goog...
2	attention_is_all_you_need.md	3	Fixo	1000 caracteres, overlap 0	49	993.20	937	1000	0.0	0.0	12167.0	[Provided proper attribution is provided, Goog...
3	attention_is_all_you_need.md	4	Fixo	2000 caracteres, overlap 0	25	1951.04	956	2000	0.0	0.0	12194.0	[Provided proper attribution is provided, Goog...
4	attention_is_all_you_need.md	5	Fixo + overlap	500 caracteres, overlap 50	109	491.54	357	500	108.0	10.0	13394.0	[Provided proper attribution is provided, Goog...
5	attention_is_all_you_need.md	6	Fixo + overlap	500 caracteres, overlap 200	163	492.30	357	500	162.0	40.0	20061.0	[Provided proper attribution is provided, Goog...
6	attention_is_all_you_need.md	7	Por parágrafo	500 caracteres, overlap 50	136	358.71	22	499	NaN	NaN	NaN	[Provided proper attribution is provided, Goog...
7	attention_is_all_you_need.md	8	Sentenças agrupadas	3 sentenças por chunk	5	10086.60	1620	14045	NaN	NaN	NaN	[Provided proper attribution is provided, Goog...
8	attention_is_all_you_need.md	9	Recursive Character	500 caracteres, overlap 50	137	364.13	26	499	NaN	NaN	NaN	[Provided proper attribution is provided, Goog...
9	attention_is_all_you_need.md	10	Markdown / estrutura semântica	#, ##, ###	28	1750.11	12	10946	NaN	NaN	NaN	[Provided proper attribution is provided, Goog...

3. Geração de arquivo json, exemplo abaixo:

```

1 [
2   {
3     "Arquivo": "attention_is_all_you_need.md",
4     "Teste": 1,
5     "Estratégia": "Fixo",
6     "Configuração": "200 caracteres, overlap 0",
7     "Qtd. chunks": 245,
8     "Tamanho médio": 192.89,
9     "Tamanho mínimo": 117,
10    "Tamanho máximo": 200,
11    "Chunks sobrepostos": 0,
12    "Overlap (%)": 0.0,
13    "Tokens estimados": 11814,
14    "Chunks": [
15      "Provided proper attribution is provided, Google hereby grants permission to use the content of this document for research and educational purposes only. All rights reserved. © 2017 Ashish Vaswani * Google Brain avaswani@google.com Noam Shazeer * Google Research nshazeer@google.com N. Gomez * † University of Toronto aidan@cs.toronto.edu Jakob Uszkoreit * Google Research uszkoreit@google.com",
16      "Provided proper attribution is provided, Google hereby grants permission to use the content of this document for research and educational purposes only. All rights reserved. © 2017 Ashish Vaswani * Google Brain avaswani@google.com Noam Shazeer * Google Research nshazeer@google.com N. Gomez * † University of Toronto aidan@cs.toronto.edu Jakob Uszkoreit * Google Research uszkoreit@google.com",
17      "Provided proper attribution is provided, Google hereby grants permission to use the content of this document for research and educational purposes only. All rights reserved. © 2017 Ashish Vaswani * Google Brain avaswani@google.com Noam Shazeer * Google Research nshazeer@google.com N. Gomez * † University of Toronto aidan@cs.toronto.edu Jakob Uszkoreit * Google Research uszkoreit@google.com",
18      "Provided proper attribution is provided, Google hereby grants permission to use the content of this document for research and educational purposes only. All rights reserved. © 2017 Ashish Vaswani * Google Brain avaswani@google.com Noam Shazeer * Google Research nshazeer@google.com N. Gomez * † University of Toronto aidan@cs.toronto.edu Jakob Uszkoreit * Google Research uszkoreit@google.com",
19      "Provided proper attribution is provided, Google hereby grants permission to use the content of this document for research and educational purposes only. All rights reserved. © 2017 Ashish Vaswani * Google Brain avaswani@google.com Noam Shazeer * Google Research nshazeer@google.com N. Gomez * † University of Toronto aidan@cs.toronto.edu Jakob Uszkoreit * Google Research uszkoreit@google.com",
20      "Provided proper attribution is provided, Google hereby grants permission to use the content of this document for research and educational purposes only. All rights reserved. © 2017 Ashish Vaswani * Google Brain avaswani@google.com Noam Shazeer * Google Research nshazeer@google.com N. Gomez * † University of Toronto aidan@cs.toronto.edu Jakob Uszkoreit * Google Research uszkoreit@google.com"
21    ]
22  }
23 ]

```

9. Geração dos Embeddings

A geração dos embeddings foi separada em outro arquivo “02_Embeddings.ipynb” e primeiramente limitado a 3 e 5 chunks por teste para maior controle de uso de Tokens, este limite pode ser facilmente modificado.

O resultado do “embedding.json” possui separação por testes, e cada chunk como na imagem abaixo:

```
embeddings_resultados.json
1 [
2   {
3     "Arquivo": "attention_is_all_you_need.md",
4     "Teste": 1,
5     "Estratégia": "Fixo",
6     "Configuração": "200 caracteres, overlap 0",
7     "Chunk": 1,
8     "Texto": "Provided proper attribution is provided, Google hereby grants permission to reproduce the tables and figures in this pape",
9     "Embedding": [
10      0.04779052734375,
11      0.0276336669921875,
12      0.0118865966796875,
13      0.044769287109375,
14      0.0240020751953125,
15      -0.03631591796875,
16      -0.03515625,
17      -0.0023517608642578125,
18      -0.050262451171875,
19      -0.09539794921875,
20      0.021728515625,
21      -0.01064300537109375,
22      0.0214691162109375,
23      -0.061737060546875,
24      0.0184783935546875,
25      0.0390625,
26      0.012542724609375,
27      -0.052825927734375,
28      0.02557373046875,
29      0.035369873046875,
```

12. Resumo dos experimentos de Extração de PDFs

A Extração dos PDFs apresenta uma dependência de organização quando o arquivo é criado pelo autor, documentos mal formatados apresentam uma extração bagunçada, corrupção de informações, perda de contexto e informações. O arquivo markdown só conseguirá seguir uma estrutura satisfatória com arquivos PDFs bem estruturados, necessitando revisões como:

Remoção de tags de imagens que não foram transferidas, tags de divisão de linhas como /n/n, má formatação de tabelas, ou caracteres e ícones especiais, que ficam com código html.

13. Resumo dos experimentos de Chunking

Os experimentos demonstraram que estratégias baseadas exclusivamente em caracteres oferecem maior controle sobre o tamanho dos chunks, porém apresentam maior risco de fragmentação de frases, conceitos e estruturas como tabelas.

O uso de overlap reduz parcialmente esse problema, mas aumenta a quantidade de chunks e a redundância, especialmente quando utilizado em proporções elevadas. O

chunking por parágrafo apresentou tamanhos intermediários e preservou melhor as unidades textuais, embora ainda tenha produzido fragmentos muito pequenos.

O RecursiveCharacterTextSplitter apresentou resultados promissores por combinar controle de tamanho com divisões mais naturais do texto. Entretanto, a estratégia que melhor preservou a estrutura semântica foi o MarkdownHeaderTextSplitter, pois manteve a organização hierárquica definida pelos headings do documento. Seu principal problema foi a geração de chunks relativamente grandes.

14. Resumo dos experimentos de embedding

A geração de embeddings de todos os chunks do menor arquivo disponível “escrita_academica_ia.md” foi inviável até pelo ambiente colab, uma vez que, os resultados são armazenados no browser, e os mesmos vão utilizando a memória do computador local, mesmo com 16gb de ram foi insuficiente.

Assim optei pela geração de embeddings de 3 e 5 chunks por testes.

A próxima etapa de análise de é a criação do Document

Análise Comparativa Obrigatória (Resultados)

Esta análise examinou o comportamento de 10 estratégias de divisão de texto (chunking) utilizando o documento ‘escrita_academica_ia’ como referência padronizada. Abaixo, apresento as conclusões obtidas:

1. Qual estratégia gerou mais chunks?

Teste 1 (Fixo - 200 caracteres com overlap)

Apresentou o maior volume de fragmentos, variando de um máximo de 1542 (gpt3_language_models) para um mínimo de 212 (escrita_academica_ia). Esta estratégia resultou em um tamanho extremamente baixo por chunk.

2. Qual gerou menos chunks?

Por Sentença (sentenças agrupadas por 3)

Manteve a estrutura mais natural, apresentando o menor número de fragmentos. Variou de 5 (escrita_academica_ia) a 29 (gpt3_language_models) chunks.

3. Como o tamanho dos chunks variou?

Nos testes fixos o tamanho estava controlado, assim quanto maior o chunk, menor o numero de chunks gerados.

Nos testes 5 e 6 a média se manteve em 500 caracteres, mas houve um aumento do número de chunks devido ao overlap.

O tamanho do chunk impacta diretamente nas unidades recuperáveis, porém não significa melhor contexto.

4. Qual estratégia preservou melhor a estrutura dos documentos?

Teste 10 - Markdown / estrutura semântica

Ele utilizou os cabeçalhos '#, ## e ###' como referência para dividir o documento e gerou menos chunks fragmentados.

Para preservar a organização lógica o *MarkdownHeaderTextSplitter* é o mais adequado.

5. Como tabelas foram tratadas?

A conversão dos PDFs para markdown utilizando o Docling preservou as tabelas, transformando em tabelas Markdown, ou seja, texto estruturado.

Exemplo do arquivo 'escrita_academica_ja':

Fase	Foco Principal	Objetivo
-----	-----	-----
Pré-escrita	...	...
Escrita	...	...

O Problema:

Fazer uma divisão por caracteres pode/irá quebrar essa estrutura.

Cabeçalho em um Chunk e linha em outra.

Chunking de Overlap e de sentenças irão apresentar muitos problemas/ perda de contexto/ quebras.

Melhores estratégias de chunking para tabelas:

- Recursiva - Recursive Splitter
- Markdown - MarkdownHeaderTextSplitter

6. Como imagens foram tratadas?

As imagens não foram preservadas como conteúdo visual dentro dos chunks.

Este foi um dos problemas que tentei resolver na conversão de PDFs para Markdown, mas não obtive um sucesso satisfatório. Algumas imagens tiveram suas legendas transcritas.

Transcrição de imagens retornou apenas '< ! - - image - - >'

Legendas/Fontes e datas de imagens quando disponíveis foram mantidas e preservadas.

Assim, uma análise não consegue compreender o conteúdo visual das imagens, apenas suas descrições.

7. Quais informações foram perdidas durante a conversão PDF → Markdown?

1. Imagens.
2. A Formatação original dos PDFs.
3. Alguns ícones foram transcritos como código html.
4. Perda de palavras quando a separação de chunks era de tamanho reduzido.
5. Ícones, imagens em tabelas.

8. O chunking por caracteres fragmentou conceitos ou estruturas importantes?

Sim

Quanto menor o número de caracteres aceito em um chunk maior a probabilidade de corte de palavras e posteriormente pior o resultado do contexto.

Quanto maior o número de caracteres menor a probabilidade da perda de contexto

9. O chunking por parágrafo produziu chunks muito grandes?

Não

Levando em consideração a análise dos resultados do documento 'escrita_academica_ia':

- Possui 123 chunks
- média de 339,69 caracteres
- mínimo de 1
- máximo de 499

Os chunks não ficaram grandes, ficando inferiores a 500 caracteres, porém podem produzir chunks excessivamente pequenos.

10. O chunking por sentença conseguiu preservar melhor o contexto?

Talvez

Levando em consideração a análise dos resultados do documento 'escrita_academica_ia':

- somente 4 chunks;
- média de 10.804,5 caracteres;
- mínimo de 10.018;
- máximo de 11.395.

Com o resultado obtido irei revisar como o teste 8 está implementado, pois não faz sentido possuir tantos caracteres por sentença.

11. O Recursive Splitter apresentou vantagens?

Sim

Levando em consideração a análise dos resultados do documento 'escrita_academica_ia':

- Gerou 125 chunks

- média de 349,04 caracteres
- máximo de 499
- mínimo de 1

Ele conseguiu produzir chunks menores sem depender de uma posição fixa, além de gerar uma separação hierárquica.

Assim ele encontra a melhor forma de dividir, diminuindo quebras de palavras.

12. O Markdown Splitter conseguiu preservar a estrutura semântica?

Sim

Utilizou os marcadores `#`, `##`, `###` e preservou a estrutura hierárquica, dando mais contexto. Porém os chunks ficam grandes.

13. Qual estratégia parece mais adequada para um sistema de RAG?

Recursive

A estratégia recursive apresenta uma quantia de chunks e tamanhos equilibrados, tornando uma escolha interessante para fazer um RAG, ainda não realizei a leitura do resultado dos embeddings para testar se estou com algum sentido.

Seria interessante separar por Markdown antes? Assim estruturaria em tópicos e depois dentro de cada tópico aplicaria uma estratégia recursiva para reduzir o tamanho dos chunks.

14. Quais estratégias devem ser descartadas?

Teste 1 - 200 caracteres

Muita perda de contexto e palavras divididas.

Teste 8 - 3 sentenças

Poucos chunks com muitos caracteres, algo ta errado ou é assim mesmo?

Teste 6 - overlap 200

Muito overlap gera muitos chunks com muitas palavras repetidas.

Teste 4 - 2000 caracteres

Muitos caracteres para poucos chunks.

15. Quais estratégias utilizar nos próximos experimentos?

Complementar o markdown com a recursividade para ver como uma estrutura hierárquica se comportaria na preservação do contexto.